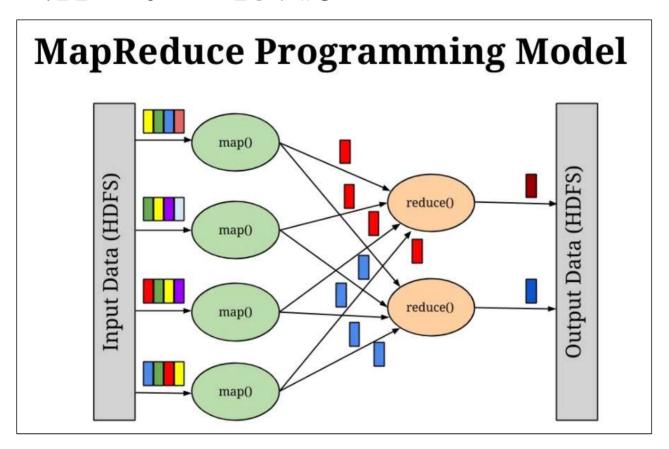
■ Spark 출현배경

- 1. Hadoop MapReduce의 한계
- 성능의 문제: 느린데다가 많은 Disk I/0
- 항상 HDFS에서 읽어서 작업, 단계별 처리를 하기 때문에 머신러닝같이 반복 작업에 비효율적
- Interactive Computing 부재
- 복잡한 configuration 설정과 튜닝



2. Hadoop과 Spark의 차이

① 역할

- 하둡: 분산형 데이터 인프라 스트럭처이며, 대량의 데이터 구조를 서버 클러스 터 환경 내에서 복수의 서버들에 분산시키는 역할
- 스파크: 하둡 또는 분산형 데이터 구조 위에서 동작하는 데이터 프로세싱 서비 스

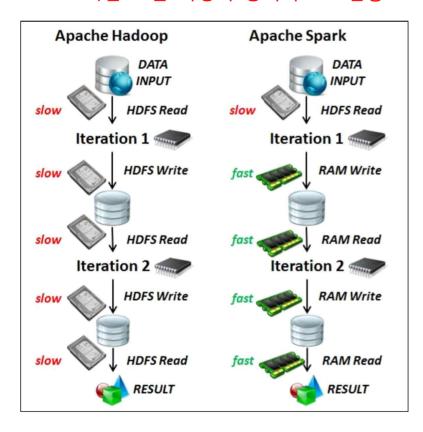
② 필요관계

- 하둡: 기본 코어는 HDFS+YARN으로 구성되고 스파크가 반드시 필요하진 않음

- 스파크: 하둡 위에서만 실행되지는 않지만 하둡 기반으로 설계가 되었기 때문에 하둡 환경 위에서 최상의 성능이 나옴

③ 성능

- 하둡(Map Reduce)이 스파크보다 성능이 낮음
- 데이터 프로세싱의 차이에 기반
- 하둡은 Disk 기반, 스파크는 Memory 기반
- 하둡: 단계별 처리 방식
- 하둡: HDFS에서 데이터 Read -> 작업실행 -> HDFS에 데이터 Write -> 다시 update된 데이터 Read -> 다음 작업 후, HDFS에 데이터 Write
- 스파크: 전체 데이터셋을 한번에 처리
- 스파크: HDFS에서 데이터 Read -> 메모리상 필요 작업 실행 및 HDFS에 데이터 Write하는 모든 과정이 동시적으로 진행



④ 적용 영역

- 하둡: 정적인 데이터 운영 및 보고 등, 배치(Batch)의 경우 M/R로 구성하면 성 능도 괜찮음
- 스파크: 스트리밍 데이터 처리, 머신러닝 알고리즘 기반의 비즈니스 로직 개발, 실시간 로그 분석 및 처리, ETL 등

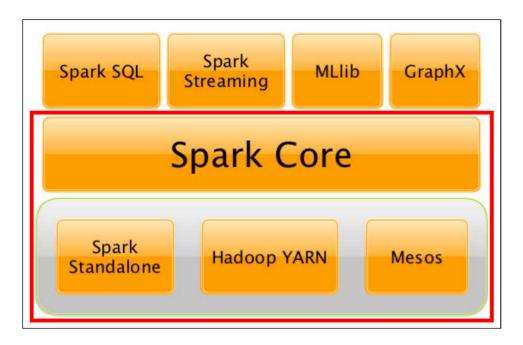
■ Spark 개요



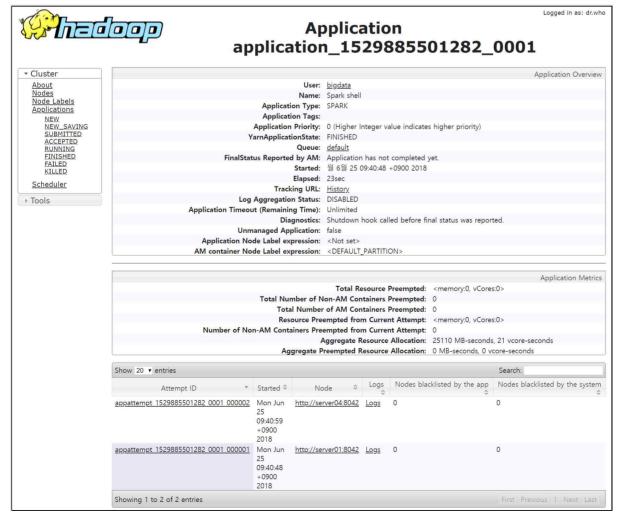
- 빅데이터 처리를 위한 오픈소스 병렬 분산처리 플랫폼
- 인메모리 기반(In-Memory)의 대용량 데이터 고속 처리 엔진
- JAVA, Python, Scala, R을 기반으로 구동
- 2009년에 UC Berkeley AMPLab 연구 프로젝트로 처음 출현
- 2010년에 오픈소스로 공개
- 2013년에 아파치 인큐베이터 프로젝트로 선정

■ Spark 특징

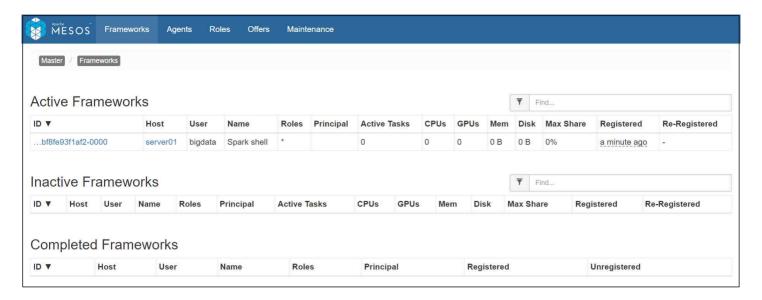
- In-Memory Processing: 하둡의 MR(MapReduce) 작업처리 속도보다 100배 이상 빠른 성능 구현
- JAVA, Python, Scala, R 인터페이스 지원
- 8000개 이상의 노드 추가 가능한 확장성 보장
- 데이터 저장 및 활용을 위해 HDFS 뿐 아니라, Cassandra, HBase, ElasticSearch, Amazon S3 등 지원
- 분산 클러스터 컴퓨팅 환경 구축을 위해 3가지 환경을 지원
- 자체적인 Standalone Scheduler환경(Single / Cluster)

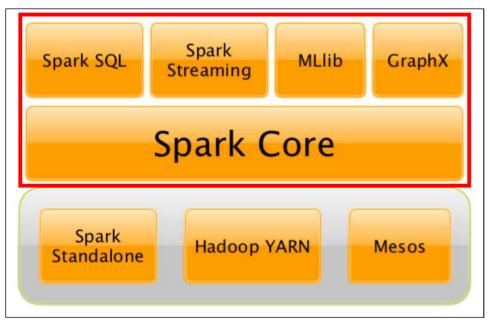


- 하둡의 종합 플랫폼인 YARN, Docker 가상화 플랫폼인 Mesos 위에서도 기동가능
- 적절한 클러스터의 수를 설정하지 않는 다면, Standalone 모드가 더 빠르기 때문에 수업에서는 Standalone 모드로 Spark 환경 구성
- Spark on yarn



- Spark on mesos

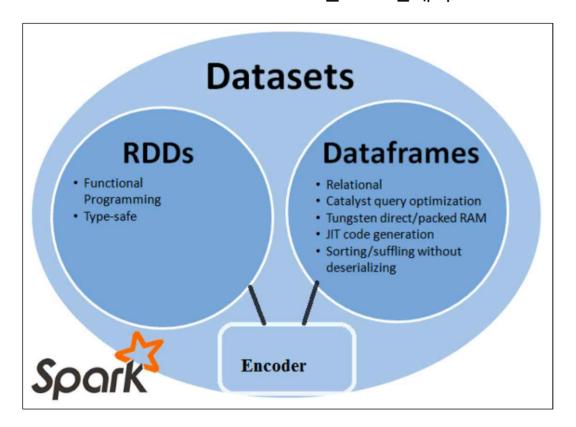




- 기존 데이터 분석을 위해서는 여러 플랫폼이 필요함
- 스파크는 이를 통합하여 공식 지원
- Spark SQL: SQL
- Spark Streaming: 단일/분산 시스템에서 배치/스트리밍 처리
- Spark MLlib: 머신러닝
- Spark GraphX: 그래프 프로세싱

■ Spark API

- Spark API는 스파크가 제공하는 Data Interface
- Spark에서 처리/분석 할 데이터의 객체 형태로, 여러 가지 Operation을 할 수 있음
- RDD -> Dataframe -> Dataset 순으로 업데이트



1 RDD

- Spark 1.0부터 있던 API
- Lamda를 이용한 transformations와 actions
- transformations: map(), filter(), reduce
- actions: collect(), saveAsObjectFile()
- compile-time type safety(자료형에 대한 안정성) 보장하지만 이해하기 어려워 접근이 어려움

```
JavaPairRDD\String, Integer\> counts = textFile
.flatMap(s -\> Arrays.asList(s.split(" ")).iterator())
.mapToPair(word -\> new Tuple2\>(word, 1))
.reduceByKey((a, b) -\> a + b);
```

② Dataframe

- Spark1.3부터 있던 API
- 데이터에 스키마를 적용하여 RDB처럼 Column과 Row형식의 Table로 표현
- 높은 레벨의 추상화가 가능하여 누구나 쉽게 적응 가능
- Catalyst optimization을 이용하여 훨씬 빠르게 처리
- Compile-time에서 type mismatch같은 에러를 잡지 못함

```
DataFrame errors = df.filter(col("line").like("%ERROR%"));

// Counts all the errors
errors.count();

// Counts errors mentioning MySQL
errors.filter(col("line").like("%MySQL%")).count();

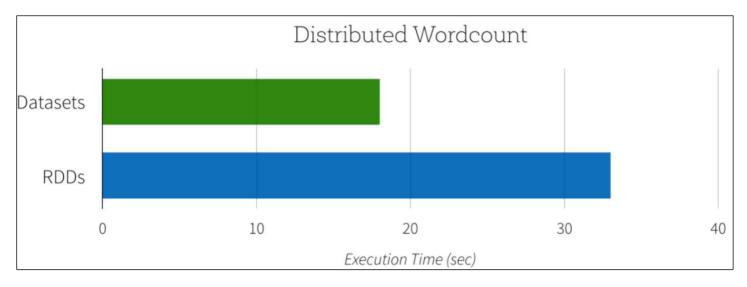
// Fetches the MySQL errors as an array of strings
errors.filter(col("line").like("%MySQL%")).collect();
```

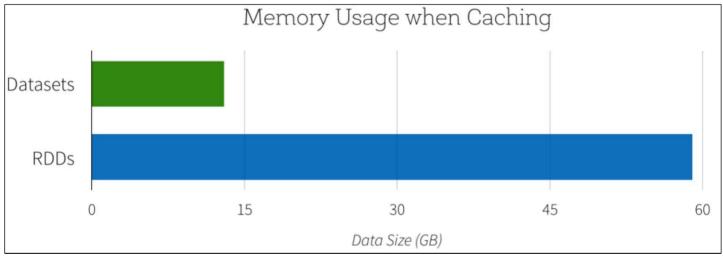
③ Dataset

- -RDD와 Dataframe의 장점 (Catalyst optimizer와 type-safety보장)을 합치면 어떨까?
- -Spark2.0부터 존재하는 API
- -Dataframe의 장점인 높은 레벨의 추상화, Catalyst optimizer을 이용하여 성능 향상
- -Java Generics를 이용하여 RDD의 장점인 Compile-time type-safety 보장

- Spark API 비교

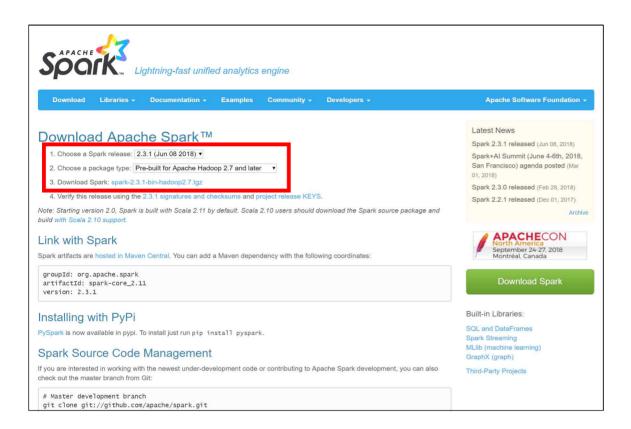
	RDD	Dataframe	Dataset
성능	느림	빠름	빠름
메모리 관리	누수 존재	최적화	최적화
Type-safety	보장	보장X	보장
확장성	유연함	제한적	유연함





- Spark 설치(standalone)
- Spark 다운로드 페이지에 접속해서 Choose a Spark release:에서 현재 최신 버전인 2.3.1 선택 후 Download Spark: spark-2.3.1-bin-hadoop2.7.tgz 클릭

https://spark.apache.org/downloads.html



- 미러사이트에서

http://mirror.navercorp.com/apache/spark/spark-2.3.1/spark-2.3.1-bin-hadoop2

.7.tgz 클릭 후 파일 다운받기



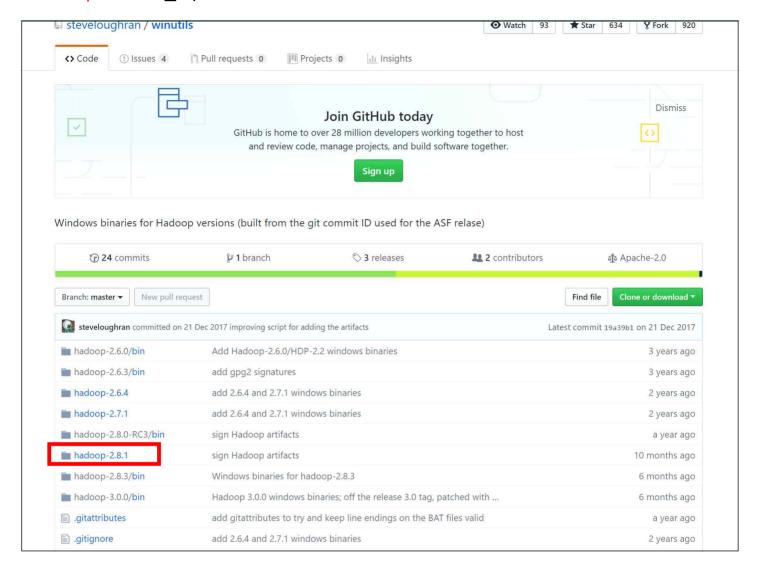
- 다운받은 스파크 파일을 C:\jbm 디렉터리에 압축을 풀기



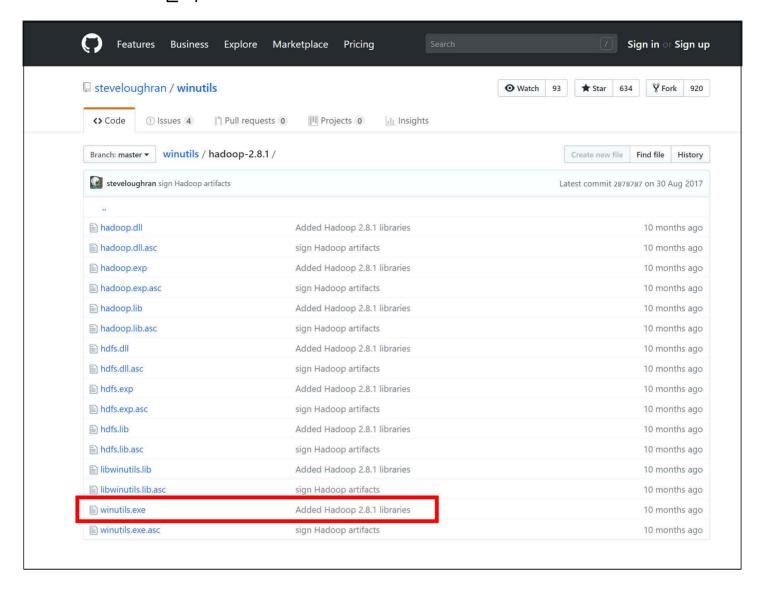
- 아래의 주소로 들어가 winutils 파일 다운
- winutils: 하둡 없이 스파크를 실행할 수 있게 해줌

https://github.com/steveloughran/winutils

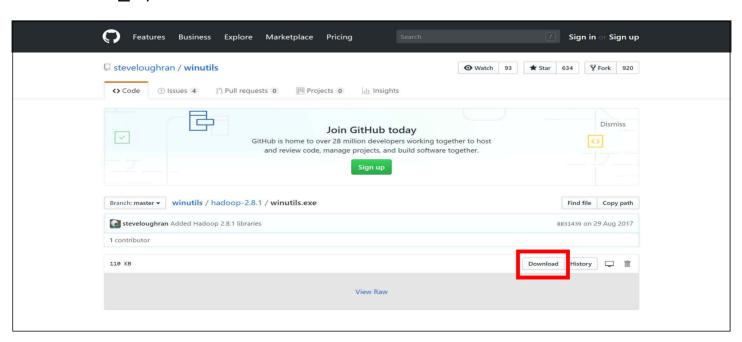
- hadoop-2.8.1 클릭



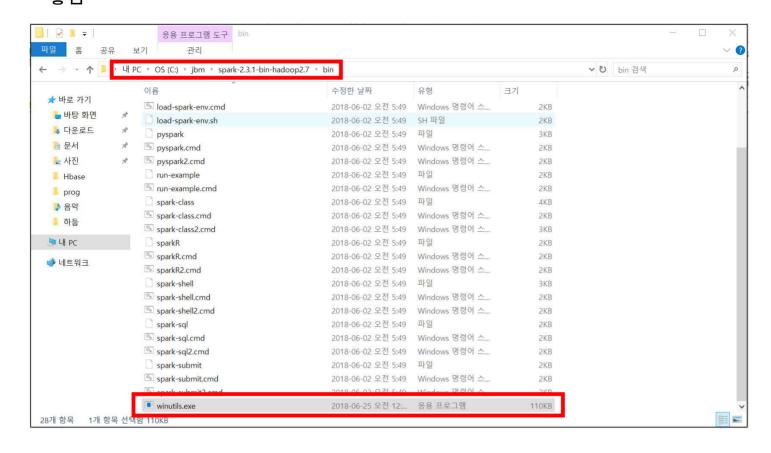
- winutils.exe 클릭



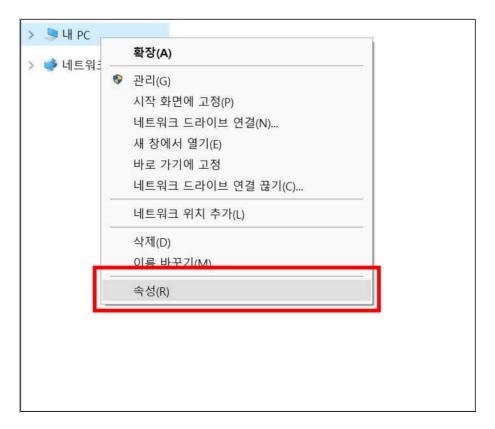
- Download 클릭



- C:\jbm\spark-2.3.1-bin-hadoop2.7\bin 경로에 다운 받은 winutils.exe를 갖다 놓음



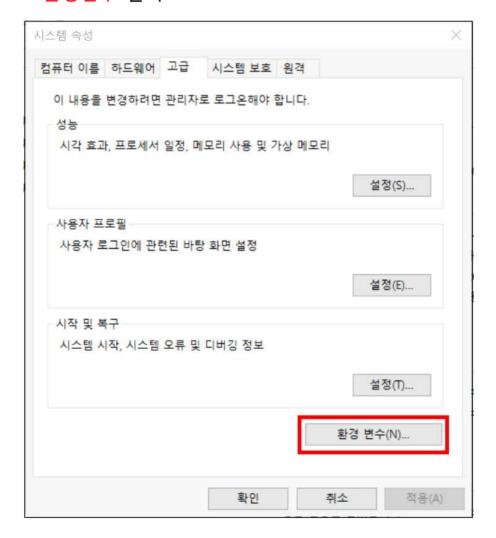
- 내 PC를 마우스 오른쪽 버튼으로 클릭해 속성 클릭



- 고급 시스템 설정 클릭



- 환경변수 클릭

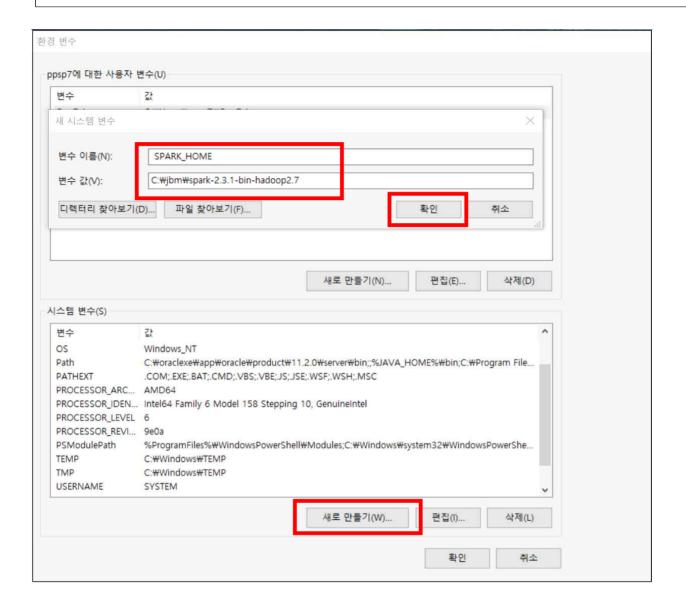


- 새로 만들기 클릭 후 아래와 같이 변수 이름, 변수 값 입력

- 확인 클릭

변수 이름: SPARK_HOME

변수 값: C:\jbm\spark-2.3.1-bin-hadoop2.7

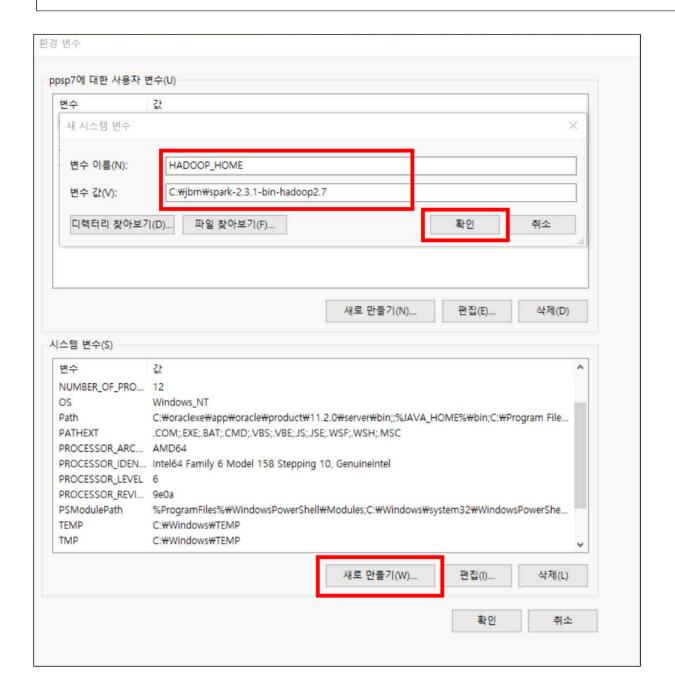


- 새로 만들기 클릭 후 아래와 같이 변수 이름, 변수 값 입력

- 확인 클릭

변수 이름: HADOOP_HOME

변수 값: C:\jbm\spark-2.3.1-bin-hadoop2.7



- cmd 창을 열어 스파크의 bin 경로로 이동

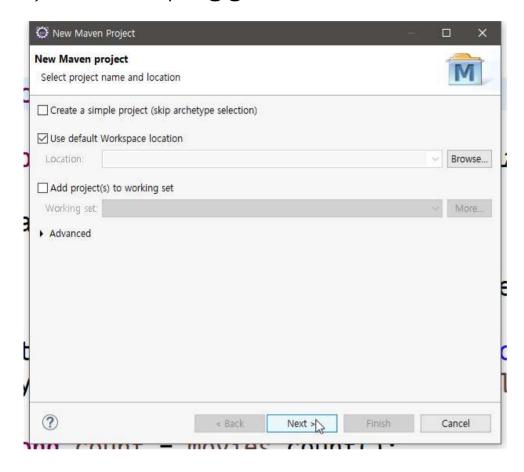
> cd c:\jbm\spark-2.3.1-bin-hadoop2.7\bin

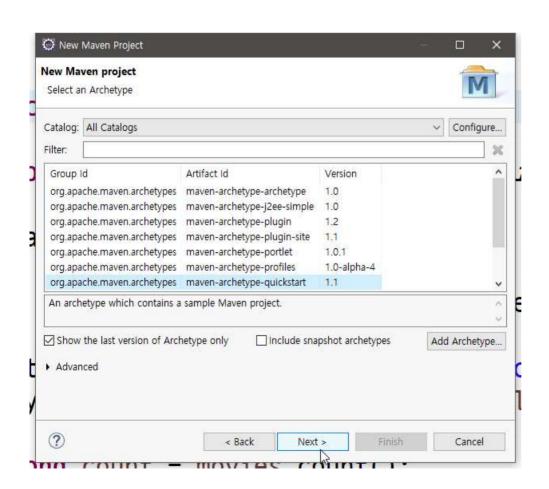
- spark-shell 접속해 설치 확인

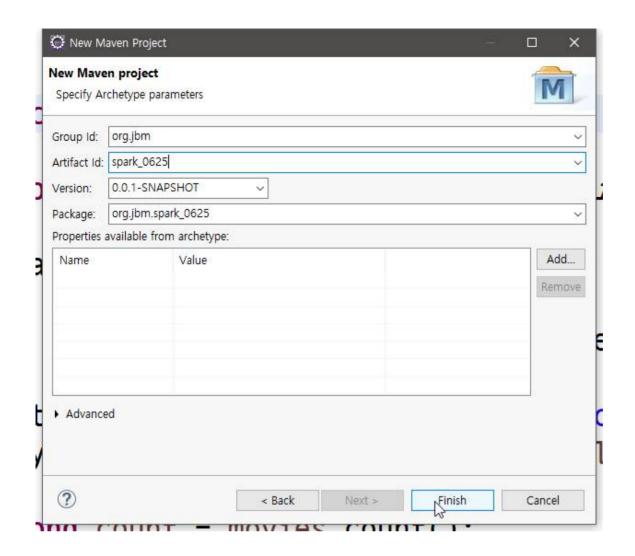
> spark-shell

■ Spark 일반 Java Application 프로그래밍

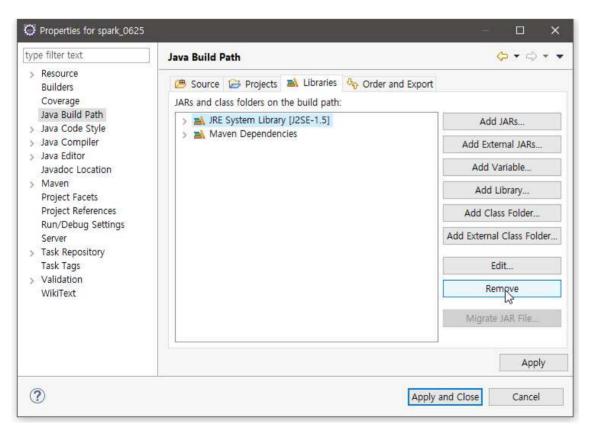
1) maven 프로젝트 생성

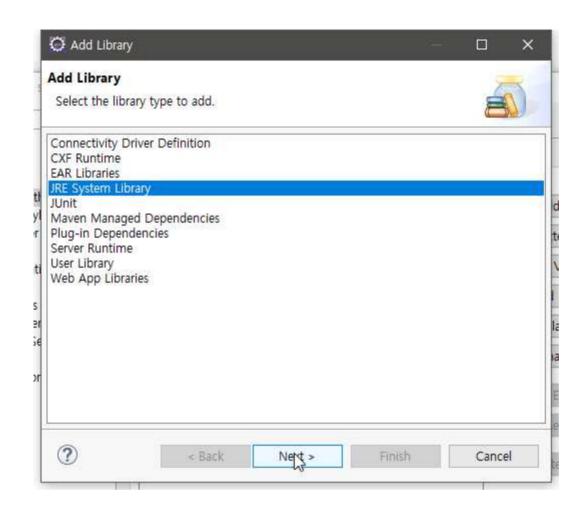


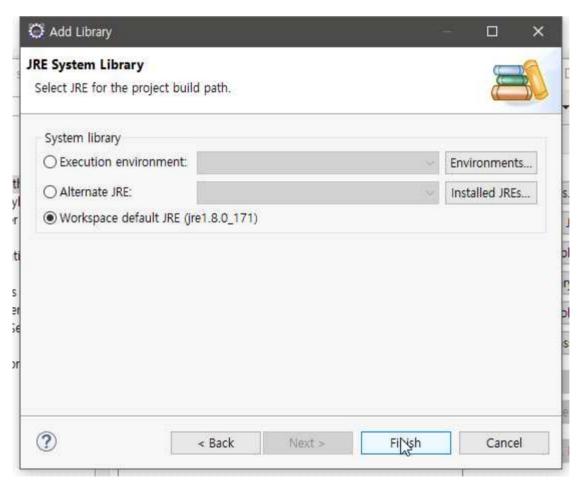


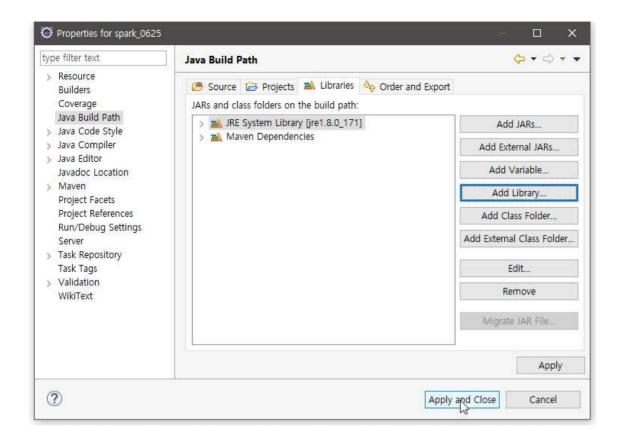


2) 자바 8 JRE system library로 변경





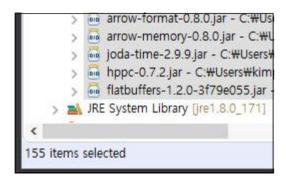




3) junit 삭제 및 test 패키지 삭제

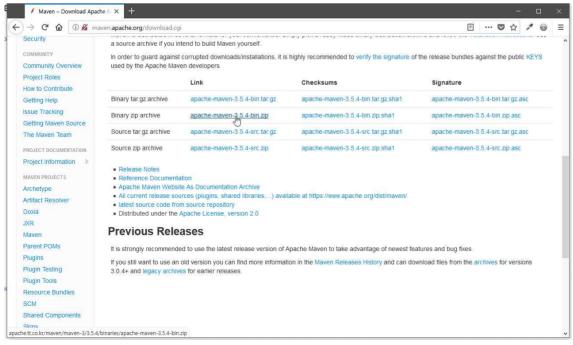
4) 필요한 라이브러리 dependency 지정

- 라이브러리 등록(155개)

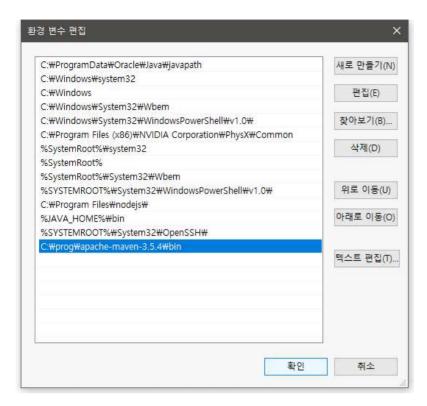


- 이 jar파일들을 복사하려면 mvn을 설치해야 함





- path 지정(maven 설치 경로/bin)

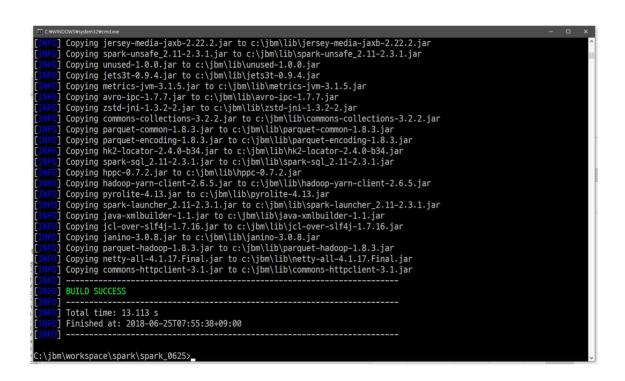


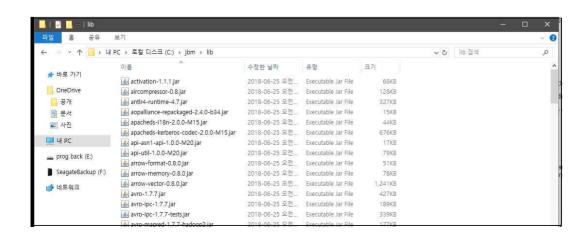
- mvn 실행 테스트(mvn -v)

- pom.xml이 있는 폴더(프로젝트 폴더)에서

C:\jbm\workspace\spark\spark 0625>mvn dependency:copy-dependencies -DoutputDirectory=c:/jbm/lib

```
:\jbm\workspace\spark\spark_0625>mvn dependency:copy-dependencies -DoutputDirectory=c:/jbm/lib
     ] Scanning for projects...
Downloading from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-install-plugin/2.4/maven-nstall-plugin-2.4.pom
Downloaded from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-install-plugin/2.4/maven-in
stall-plugin-2.4.pom (6.4 kB at 5.1 kB/s)
 ownloading from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-deploy-plugin/2.7/maven-de
ploy-plugin-2.7.pom
Oownloaded from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-deploy-plugin/2.7/maven-dep
loy-plugin-2.7.pom (5.6 kB at 18 kB/s)
Downloading from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-site-plugin/3.3/maven-site
-plugin-3.3.pom
Downloaded from central: https://repo.mayen.apache.org/mayen2/org/apache/mayen/plugins/mayen-site-plugin/3.3/mayen-site
plugin-3.3.pom (21 kB at 47 kB/s)
ownloading from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-antrun-plugin/1.3/maven-an
trun-plugin-1.3.pom
Downloaded from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-antrun-plugin/1.3/maven-ant
run-plugin-1.3.pom (4.7 kB at 14 kB/s)
Downloading from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-plugins/12/maven-plugins-1
Downloaded from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-plugins/12/maven-plugins-12
.pom (12 kB at 37 kB/s)
trun-plugin-1.3.jar
Downloaded from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-antrun-plugin/1.3/maven-ant
run-plugin-1.3.jar (24 kB at 63 kB/s)
Downloading from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-assembly-plugin/2.2-beta-5
/maven-assembly-plugin-2.2-beta-5.pom
Downloaded from central: https://repo.maven.apache.org/maven2/org/apache/maven/plugins/maven-assembly-plugin/2.2-beta-5
maven-assembly-plugin-2.2-beta-5.pom (15 kB at 48 kB/s)
```





- Spark가 가진 RDD / DataFrame / DataSet중 RDD 기본 예제 수행

```
public class SparkApp {

public static void main(String[] args) {

SparkConf conf = new SparkConf().setAppName("SparkTest").setMaster("local");

JavaSparkContext jsc = new JavaSparkContext(conf);

JavaRDD<String> ratingData =

jsc.textFile("hdfs://192.168.56.101:8020/user/hive/warehouse/chickens").cache();

// JavaRDD<String> ratingData = jsc.textFile("src/assets/").cache();

System.out.println("치킨 시킨 횟수: "+ratingData.count());

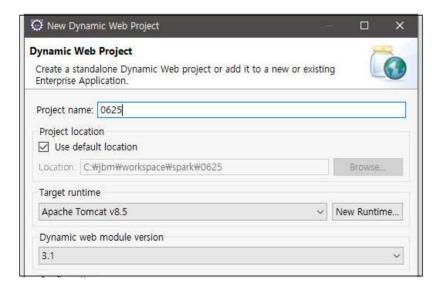
}

}
```

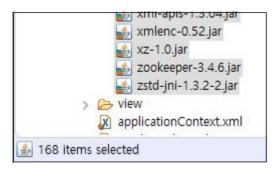
```
MemoryStore: Block rdd 1 1 stored as values in memory (estimated size 4.0 MB, free 4.1 GB)
18/06/25 08:09:46 INFO BlockManagerInfo: Added rdd 1 1 in memory on DESKTOP-MUP3PD0:8211 (size: 4.0 MB, free: 4.1 GB)
18/06/25 08:09:46 INFO Executor: Finished task 1.0 in stage 0.0 (TID 1). 832 bytes result sent to driver
18/06/25 08:09:46 INFO TaskSetManager: Finished task 1.0 in stage 0.0 (TID 1) in 118 ms on localhost (executor driver) (2/2)
18/06/25 08:09:47 INFO TaskSchedulerImpl: Removed TaskSet 0.0, whose tasks have all completed, from pool
18/06/25 08:09:47 INFO DAGScheduler: ResultStage 0 (count at SparkApp.java:18) finished in 0.637 s
18/06/25 08:09:47 INFO DAGScheduler: Job 0 finished: count at SparkApp.java:18, took 0.675487 s
치킨 시킨 횟수 : 71149
18/06/25 08:09:47 INFO SparkContext: Invoking stop() from shutdown hook
18/06/25 08:09:47 INFO SparkUI: Stopped Spark web UI at http://DESKTOP-MUP3PD0:4040
18/06/25 08:09:47 INFO MapOutputTrackerMasterEndpoint: MapOutputTrackerMasterEndpoint stopped!
18/06/25 08:09:47 INFO MemoryStore: MemoryStore cleared
18/06/25 08:09:47 INFO BlockManager: BlockManager stopped
18/06/25 08:09:47 INFO BlockManagerMaster: BlockManagerMaster stopped
18/06/25 08:09:47 INFO OutputCommitCoordinator$OutputCommitCoordinatorEndpoint: OutputCommitCoordinator stopped!
18/06/25 08:09:47 INFO SparkContext: Successfully stopped SparkContext
18/06/25 08:09:47 INFO ShutdownHookManager: Shutdown hook called
18/06/25 08:09:47 INFO ShutdownHookManager: Deleting directory C:\Users\kimpi\AppData\Local\Temp\spark-83b55e64-fe7a-48f5-9542-e79f4d270de8
```

■ Spark Spring 연동 프로그래밍

1) Dynamic Web Project로 생성



2) lib에 spring + spark 라이브러리 전부 복사



3) 기본 Spring 설정은 변함 없음

- web.xml

```
<?xml version="1.0" encoding="UTF-8"?>
                                                  xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
<web-app
xmlns="http://xmlns.jcp.org/xml/ns/javaee"
                                                 xsi:schemaLocation="http://xmlns.jcp.org/xml/ns/javaee
http://xmlns.jcp.org/xml/ns/javaee/web-app 3 1.xsd" id="WebApp ID" version="3.1">
  <filter>
   <filter-name>encoding</filter-name>
   <filter-class>org.springframework.web.filter.CharacterEncodingFilter</filter-class>
   <init-param>
     <param-name>encoding</param-name>
     <param-value>UTF-8</param-value>
    </init-param>
  </filter>
  <filter-mapping>
   <filter-name>encoding</filter-name>
    <url-pattern>/*</url-pattern>
  </filter-mapping>
  <filter>
    <filter-name>httpMethodFilter</filter-name>
   <filter-class>org.springframework.web.filter.HiddenHttpMethodFilter</filter-class>
  </filter>
  <filter-mapping>
   <filter-name>httpMethodFilter</filter-name>
   <url-pattern>/*</url-pattern>
  </filter-mapping>
  <listener>
   context.ContextLoaderListener/listener-class>
  </listener>
  <servlet>
    <servlet-name>spark</servlet-name>
   <servlet-class>org.springframework.web.servlet.DispatcherServlet</servlet-class>
    <load-on-startup>1</load-on-startup>
  </servlet>
  <servlet-mapping>
```

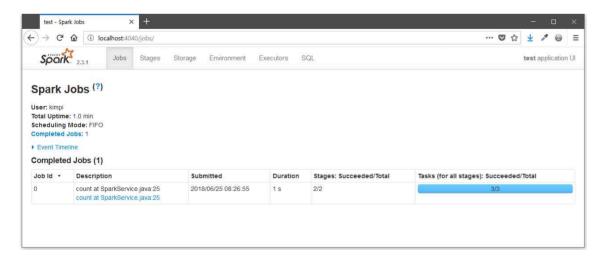
applicationContext.xml

- spark-servet.xml

```
<?xml version="1.0" encoding="UTF-8"?>
<beans xmlns="http://www.springframework.org/schema/beans"</pre>
       xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
       xmlns:mvc="http://www.springframework.org/schema/mvc"
       xmlns:p="http://www.springframework.org/schema/p"
       xmlns:websocket="http://www.springframework.org/schema/websocket"
       xsi:schemaLocation="http://www.springframework.org/schema/websocket
http://www.springframework.org/schema/websocket/spring-websocket.xsd
              http://www.springframework.org/schema/mvc
http://www.springframework.org/schema/mvc/spring-mvc-4.3.xsd
              http://www.springframework.org/schema/beans
http://www.springframework.org/schema/beans/spring-beans.xsd">
<mvc:annotation-driven/>
<!-- resource -->
<mvc:resources location="/css/" mapping="/css/**"/>
<mvc:resources location="/img/" mapping="/img/**"/>
```

```
<mvc:resources location="/upload/" mapping="/upload/**"/>
<mvc:resources location="/profile/" mapping="/profile/**"/>
<mvc:resources location="/poster/" mapping="/poster/**"/>
<mvc:resources location="/js/" mapping="/js/**"/>
<!-- /WEB-INF/view/와 .jsp가 반복 -->
<mvc:view-resolvers>
        <mvc:jsp
        prefix="/WEB-INF/view/"
         suffix=".jsp"/>
</mvc:view-resolvers>
<bean id="sparkService" p:sparkSession-ref="sparkSession" class="com.jbm.spark.util.SparkService"/>
<bean
p:sparkService-ref="sparkService"
class="com.jbm.spark.controller.AjaxController"/>
<bean p:test-ref="test"</pre>
class="com.jbm.spark.controller.IndexController"/>
</beans>
```

- RDD나 DataSet(DataFrame)을 사용하려면 SparkConf나 SparkSession이 필요함
- SparkConf나 SparkSession을 만들면 Spark Master가 실행됨



- Spring 실행시 우리가 필요한 객체를 bean으로 생성하고 등록하려면 @Configuration을 이용하면 됨

```
package com.jbm.spark.configuration;
import org.apache.spark.sql.SparkSession;
import org.springframework.context.annotation.Bean;
import org.springframework.context.annotation.Configuration;
@Configuration
public class WebApplicationConfig {
        @Bean
        public String test() {
                System.out.println("zzz");
                return "test입니다";
        }
        @Bean
        public SparkSession sparkSession() {
                System.out.println("sparkSession 시작!");
                SparkSession spark = SparkSession.builder().appName("Spark")
                                .master("local")
                                .getOrCreate();
                System.out.println("sparkSession 끝!");
                System.out.println(spark);
                return spark;
        }
}
```

- applcationContext.xml에서

```
<context:annotation-config/>
<bean class="com.jbm.spark.configuration.WebApplicationConfig"/>
```

- Spring 시작시 실행 후 bean으로 등록됨

```
sparkSession 시작!
Jsing Spark's default log4j profile: org/ap
18/06/25 08:26:16 INFO SparkContext: Runnin
18/06/25 08:26:16 WARN NativeCodeLoader: U
18/06/25 08:26:16 INFO SparkContext: Submi
18/06/25 08:26:17 INFO SecurityManager: Cha
18/06/25 08:26:17 INFO SecurityManager: Chi
18/06/25 08:26:17 INFO SecurityManager: Cha
18/06/25 08:26:17 INFO SecurityManager: Cha
18/06/25 08:26:17 INFO SecurityManager: Sec
18/06/25 08:26:17 INFO Utils: Successfully
18/06/25 08:26:17 INFO SparkEnv: Registerin
18/06/25 08:26:17 INFO SparkEnv: Registerin
18/06/25 08:26:17 INFO BlockManagerMasterEn
18/06/25 08:26:17 INFO BlockManagerMasterEr
18/06/25 08:26:17 INFO DiskBlockManager: C
18/06/25 08:26:17 INFO MemoryStore: Memory
18/06/25 08:26:17 INFO SparkEnv: Registeri
18/06/25 08:26:18 INFO Utils: Successfully
18/06/25 08:26:18 INFO SparkUI: Bound Spark
18/06/25 08:26:18 INFO Executor: Starting e
18/06/25 08:26:18 INFO Utils: Successfully
18/06/25 08:26:18 INFO NettyBlockTransferS
18/06/25 08:26:18 INFO BlockManager: Using
18/06/25 08:26:18 INFO BlockManagerMaster:
18/06/25 08:26:18 INFO BlockManagerMasterEn
18/06/25 08:26:18 INFO BlockManagerMaster
18/06/25 08:26:18 INFO BlockManager: Initia
sparkSession 끝!
org.apache.spark.sql.SparkSession@7bea8999
```

- SparkService 클래스에 필요한 메서드를 정의함

```
public long getMovieRating() {
    long start = System.currentTimeMillis();
    Dataset<String> ratings =
    sparkSession.read().textFile("hdfs://192.168.56.101:8020/user/hive/warehouse/test.db/ratings/");
    String sql = "select * from ratings";
    System.out.println("Running: " + sql);
    ratings.show();
    long count = ratings.count();
    long time = System.currentTimeMillis() - start;
    System.out.println("수행시간: " + time + "ms");
    return count;
}
```

- Controller에 주입받아 메서드 호출

```
package com.jbm.spark.controller;
import org.springframework.web.bind.annotation.RequestMapping;
import org.springframework.web.bind.annotation.RestController;
import com.jbm.spark.util.SparkService;
@RestController
public class AjaxController {
        private SparkService sparkService;
        public void setSparkService(SparkService sparkService) {
                this.sparkService = sparkService;
        }
        @RequestMapping("/ajax/chicken")
        public String count() {
                long count = sparkService.getCount();
                return "{\"chicken\":"+count+"}";
        }
        @RequestMapping("/ajax/rating")
        public String rating() {
                long count = sparkService.getMovieRating();
                return "{\"movie\":"+count+"}";
        }
}
```